

# TIDB 源码阅读系列文章(五)TIDB SQL Parser 的实

現決方案

语言 语言

文档 全部

客户案例

免费试用

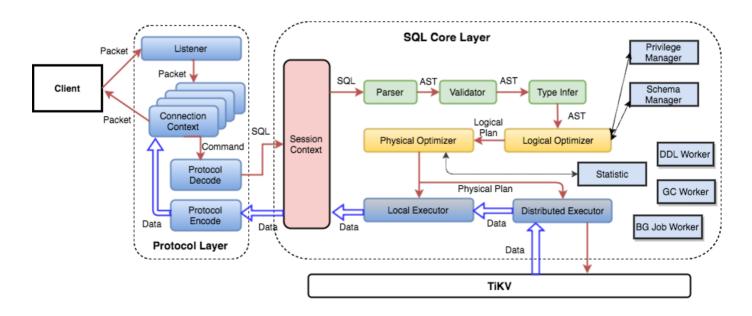
**写真**作伙伴 2018-03-20

#### 服务与支持

本文为 TiDB 源码阅读系列文章的第五篇,主要对 SQL Parser 功能的实现进行了讲解,内 学习与社区 容来自社区小伙伴——马震(GitHub ID:mz1999 )的投稿。

TiDB 源码阅读系列文章的撰写初衷,就是希望能与数据库研究者、爱好者进行深入交流,我们欣喜于如此短的时间内就收到了来自社区的反馈。后续,也希望有更多小伙伴加入到与 TiDB 『坦诚相见』的阵列中来。

PingCAP 发布了 TiDB 的 源码阅读系列文章 ,让我们可以比较系统的去学习了解TiDB的内部实现。最近的一篇 《SQL 的一生》 ,从整体上讲解了一条 SQL 语句的处理流程,从网络上接收数据,MySQL 协议解析和转换,SQL 语法解析,查询计划的制定和优化,查询计划执行,到最后返回结果。



其中, SQL Parser 的功能是把 SQL 语句按照 SQL 语法规则进行解析,将文本转换成抽象语法树(AST),这部分功能需要些背景知识才能比较容易理解,我尝试做下相关知识的介

绍,希望能对读懂这部分代码有点帮助。

TiDB 是使用 goyacc 根据预定义的 SQL 语法规则文件 parser.y 生成 SQL 语法解析器。我们可以在 TiDB 的 Makefile 文件中看到这个过程,先 build goyacc 工具,然后使用 goyacc 根据 parser.y 生成解析器 parser.go :

```
goyacc:
```

```
$(GOBUILD) -o bin/goyacc parser/goyacc/main.go
```

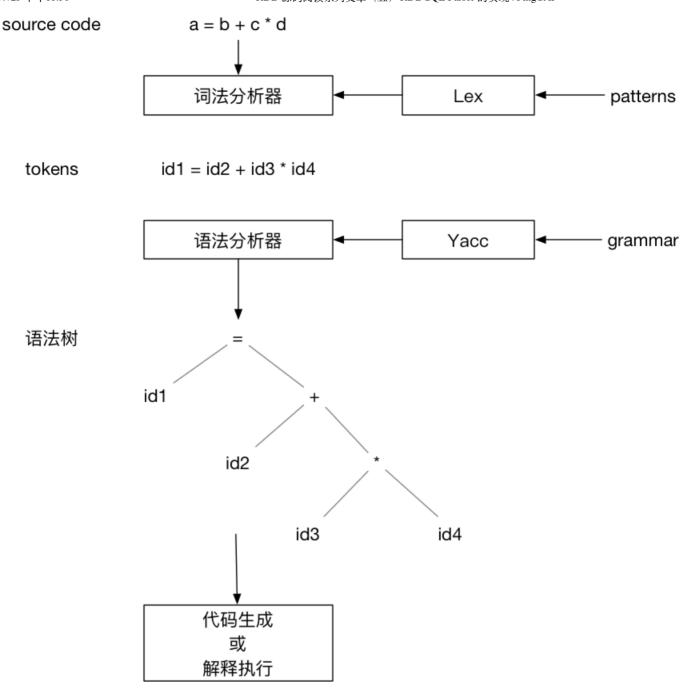
#### parser: goyacc

```
bin/goyacc -o /dev/null parser/parser.y
bin/goyacc -o parser/parser.go parser/parser.y 2>&1 ...
```

goyacc 是 yacc 的 Golang 版,所以要想看懂语法规则定义文件 parser.y ,了解解析器是如何工作的,先要对 Lex & Yacc 有些了解。

# Lex & Yacc 介绍

Lex & Yacc 是用来生成词法分析器和语法分析器的工具,它们的出现简化了编译器的编写。
Lex & Yacc 分别是由贝尔实验室的 Mike Lesk 和 Stephen C. Johnson 在 1975 年发布。对于
Java 程序员来说,更熟悉的是 ANTLR , ANTLR 4 提供了 Listener + Visitor 组合
接口,不需要在语法定义中嵌入 actions ,使应用代码和语法定义解耦。 Spark 的 SQL
解析就是使用了 ANTLR 。 Lex & Yacc 相对显得有些古老,实现的不是那么优雅,不过我们也不需要非常深入的学习,只要能看懂语法定义文件,了解生成的解析器是如何工作的就够了。
我们可以从一个简单的例子开始:



上图描述了使用 Lex & Yacc 构建编译器的流程。 Lex 根据用户定义的 patterns 生成词法分析器。词法分析器读取源代码,根据 patterns 将源代码转换成 tokens 输出。 Yacc 根据用户定义的语法规则生成语法分析器。语法分析器以词法分析器输出的 tokens 作为输入,根据语法规则创建出语法树。最后对语法树遍历生成输出结果,结果可以是产生机器代码,或者是边遍历 AST 边解释执行。

从上面的流程可以看出,用户需要分别为 Lex 提供 patterns 的定义,为 Yacc 提供 语法规则文件, Lex & Yacc 根据用户提供的输入文件,生成符合他们需求的词法分析器和语 法分析器。这两种配置都是文本文件,并且结构相同:

```
... definitions ...
```

응응

```
... rules ... %%
... subroutines ...
```

文件内容由 **%%** 分割成三部分,我们重点关注中间规则定义部分。对于上面的例子, **Lex** 的输入文件如下:

```
. . .
용용
/* 变量 */
[a-z] {
           yylval = *yytext - 'a';
           return VARIABLE;
        }
/* 整数 */
[0-9]+ {
           yylval = atoi(yytext);
           return INTEGER;
        }
/* 操作符 */
[-+()=/*\n] { return *yytext; }
/* 跳过空格 */
[\t];
/* 其他格式报错 */
       yyerror("invalid character");
응용
. . .
```

上面只列出了规则定义部分,可以看出该规则使用正则表达式定义了变量、整数和操作符等几种 token 。例如整数 token 的定义如下:

当输入字符串匹配这个正则表达式,大括号内的动作会被执行:将整数值存储在变量 yylval 中,并返回 token 类型 INTEGER 给 Yacc 。

再来看看 Yacc 语法规则定义文件:

```
%token INTEGER VARIABLE
%left '+' '-'
%left '*' '/'
. . .
응응
program:
        program statement '\n'
statement:
                                  { printf("%d\n", $1); }
        expr
        | VARIABLE '=' expr
                                \{ sym[\$1] = \$3; \}
expr:
        INTEGER
         VARIABLE
                                  \{ \$\$ = sym[\$1]; \}
         expr '+' expr
                                \{ \$\$ = \$1 + \$3; \}
         expr '-' expr
                                 \{ \$\$ = \$1 - \$3; \}
                                 \{ \$\$ = \$1 * \$3; \}
         expr '*' expr
         expr'/'expr
                                 \{ \$\$ = \$1 / \$3; \}
         | '(' expr ')'
                                  \{ \$\$ = \$2; \}
일 일
```

第一部分定义了 token 类型和运算符的结合性。四种运算符都是左结合,同一行的运算符优先级相同,不同行的运算符,后定义的行具有更高的优先级。

语法规则使用了 BNF 定义。 BNF 可以用来表达上下文无关(context-free)语言,大部分的现代编程语言都可以使用 BNF 表示。上面的规则定义了三个产生式。产生式冒号左边的项(例如 statement )被称为非终结符, INTEGER 和 VARIABLE 被称为终结符,它们是由 Lex 返回的 token 。终结符只能出现在产生式的右侧。可以使用产生式定义的语法生成表达式:

```
expr -> expr * expr
-> expr * INTEGER
-> expr + expr * INTEGER
-> expr + INTEGER * INTEGER
-> INTEGER + INTEGER * INTEGER
```

解析表达式是生成表达式的逆向操作,我们需要归约表达式到一个**非终结符**。 **Yacc** 生成的语法分析器使用**自底向上**的归约(*shift-reduce*)方式进行语法解析,同时使用堆栈保存中间状态。还是看例子,表达式 **x** + **y** \* **z** 的解析过程:

```
1
    x + y * z
2
    x \cdot + y \cdot z
    expr. + y * z
4
    expr + . y * z
5
    expr + y \cdot * z
6
    expr + expr . * z
7
    expr + expr * . z
    expr + expr * z .
9
    expr + expr * expr .
10
   expr + expr .
11 expr.
12
    statement .
13 program .
```

点( . )表示当前的读取位置,随着 . 从左向右移动,我们将读取的 token 压入堆 栈,当发现堆栈中的内容匹配了某个**产生式**的右侧,则将匹配的项从堆栈中弹出,将该**产生式**左侧 的**非终结符**压入堆栈。这个过程持续进行,直到读取完所有的 tokens ,并且只有**启始非终结** 符(本例为 program )保留在堆栈中。

产生式右侧的大括号中定义了该规则关联的动作,例如:

```
expr: expr '*' expr \{ \$\$ = \$1 * \$3; \}
```

我们将堆栈中匹配该**产生式**右侧的项替换为**产生式**左侧的**非终结符**,本例中我们弹出 expr '\*' expr ,然后把 expr 压回堆栈。 我们可以使用 \$position 的形式访问堆栈中的项, \$1 引用的是第一项, \$2 引用的是第二项,以此类推。 \$\$ 代表的是归约操作执行后的 堆栈顶。本例的动作是将三项从堆栈中弹出,两个表达式相加,结果再压回堆栈顶。

上面例子中语法规则关联的动作,在完成语法解析的同时,也完成了表达式求值。一般我们希望语 法解析的结果是一棵抽象语法树( AST ),可以这么定义语法规则关联的动作:

```
용용
. . .
expr:
    INTEGER
                        \{ \$\$ = con(\$1); \}
    VARIABLE
                         \{ \$\$ = id(\$1); \}
    expr '+' expr
                        \{ \$\$ = opr('+', 2, \$1, \$3); \}
    expr '-' expr
                         \{ \$\$ = opr('-', 2, \$1, \$3); \}
                         \{ \$\$ = opr('*', 2, \$1, \$3); \}
    expr '*' expr
    expr '/' expr
                        \{ \$\$ = opr('/', 2, \$1, \$3); \}
    '(' expr ')'
                        \{ \$\$ = \$2; \}
일 일
nodeType *con(int value) {
}
nodeType *id(int i) {
    . . .
}
nodeType *opr(int oper, int nops, ...) {
}
```

上面是一个语法规则定义的片段,我们可以看到,每个规则关联的动作不再是求值,而是调用相应的函数,该函数会返回抽象语法树的节点类型 nodeType ,然后将这个节点压回堆栈,解析完成时,我们就得到了一颗由 nodeType 构成的抽象语法树。对这个语法树进行遍历访问,可以生成机器代码,也可以解释执行。

至此,我们大致了解了 Lex & Yacc 的原理。其实还有非常多的细节,例如如何消除语法的歧义,但我们的目的是读懂 TiDB 的代码,掌握这些概念已经够用了。

# goyacc 简介

goyacc 是 golang 版的 Yacc 。和 Yacc 的功能一样, goyacc 根据输入的语法规则 文件,生成该语法规则的 go 语言版解析器。 goyacc 生成的解析器 yyParse 要求词法分析器符合下面的接口:

```
type yyLexer interface {
   Lex(lval *yySymType) int
```

```
2021/9/25 下午11:38
```

```
Error(e string)
}
```

或者

```
type yyLexerEx interface {
    yyLexer
    // Hook for recording a reduction.
    Reduced(rule, state int, lval *yySymType) (stop bool) // Client should copy
}
```

TiDB 没有使用类似 Lex 的工具生成词法分析器,而是纯手工打造,词法分析器对应的代码是 parser/lexer.go , 它实现了 goyacc 要求的接口:

```
// Scanner implements the yyLexer interface.
type Scanner struct {
       reader
   buf bytes.Buffer
                 []error
    stmtStartPos int
    // For scanning such kind of comment: /*! MySQL-specific code */ or /*+ opti
    specialComment specialCommentScanner
    sqlMode mysql.SQLMode
}
// Lex returns a token and store the token value in v.
// Scanner satisfies yyLexer interface.
// 0 and invalid are special token id this function would return:
// return 0 tells parser that scanner meets EOF,
// return invalid tells parser that scanner meets illegal character.
func (s *Scanner) Lex(v *yySymType) int {
   tok, pos, lit := s.scan()
   v.offset = pos.Offset
   v.ident = lit
    . . .
}
// Errors returns the errors during a scan.
```

另外 lexer 使用了 字典树 技术进行 token 识别, 具体的实现代码在 parser/misc.go

# TiDB SQL Parser 的实现

终于到了正题。有了上面的背景知识,对 TiDB 的 SQL Parser 模块会相对容易理解一些。
TiDB 的词法解析使用的 手写的解析器 (这是出于性能考虑),语法解析采用 goyacc 。先看 SQL 语法规则文件 parser.y , goyacc 就是根据这个文件生成SQL语法解析器的。

parser.y 有 6500 多行,第一次打开可能会被吓到,其实这个文件仍然符合我们上面介绍过的结构:

```
... definitions ...
%%
... rules ...
%%
... subroutines ...
```

parser.y 第三部分 subroutines 是空白没有内容的,所以我们只需要关注第一部分 definitions 和第二部分 rules 。

第一部分主要是定义 token 的类型、优先级、结合性等。注意 union 这个联合体结构体:

```
%union {
    offset int // offset
    item interface{}
    ident string
    expr ast.ExprNode
    statement ast.StmtNode
}
```

该联合体结构体定义了在语法解析过程中被压入堆栈的项的属性和类型。

压入堆栈的项可能是 终结符 , 也就是 token , 它的类型可以是 item 或 ident ;

这个**项**也可能是 非终结符 ,即产生式的左侧,它的类型可以是 expr 、 statement 、 item 或 ident 。

goyacc 根据这个 union 在解析器里生成对应的 struct 是:

```
type yySymType struct {
   yys    int
   offset   int // offset
   item    interface{}
   ident    string
   expr    ast.ExprNode
   statement ast.StmtNode
}
```

在语法解析过程中, **非终结符** 会被构造成抽象语法树( **AST** )的节点 ast.ExprNode 或 ast.StmtNode 。抽象语法树相关的数据结构都定义在 ast 包中,它们大都实现了 ast.Node 接口:

```
// Node is the basic element of the AST.
// Interfaces embed Node should have 'Node' name suffix.
type Node interface {
   Accept(v Visitor) (node Node, ok bool)
   Text() string
   SetText(text string)
}
```

这个接口有一个 Accept 方法,接受 Visitor 参数,后续对 AST 的处理,主要依赖这个 Accept 方法,以 Visitor 模式遍历所有的节点以及对 AST 做结构转换。

```
// Visitor visits a Node.
type Visitor interface {
    Enter(n Node) (node Node, skipChildren bool)
    Leave(n Node) (node Node, ok bool)
}
```

例如 plan.preprocess 是对 AST 做预处理,包括合法性检查以及名字绑定。

union 后面是对 token 和 非终结符 按照类型分别定义:

```
/* 这部分的 token 是 ident 类型 */
         <ident>
%token
    . . .
                  "ADD"
   add
                   "ALL"
   all
                    "ALTER"
   alter
                      "ANALYZE"
   analyze
   and
                  "AND"
                 "AS"
   as
                  "ASC"
   asc
                      "BETWEEN"
   between
                     "BIGINT"
   bigIntType
    . . .
/* 这部分的 token 是 item 类型 */
        <item>
%token
   /*yy:token "1.%d"
                       */ floatLit
                                            "floating-point literal"
   /*yy:token "1.%d"
                       */ decLit
                                             "decimal literal"
    /*yy:token "%d"
                       */
                            intLit
                                             "integer literal"
                       */
    /*yy:token "%x"
                                             "hexadecimal literal"
                            hexLit
                                             "bit literal"
   /*yy:token "%b"
                       */
                            bitLit
   andnot
   assignmentEq
             "="
   eq
             ">="
    ge
    . . .
/* 非终结符按照类型分别定义 */
       <expr>
%type
   Expression
                         "expression"
   BoolPri
                          "boolean primary expression"
   ExprOrDefault
                            "expression or default"
                            "Predicate expression factor"
   PredicateExpr
                          "Set variable statement value's expression"
   SetExpr
%type
        <statement>
                        "Check table statement or show ddl statement"
   AdminStmt
   AlterTableStmt
                             "Alter table statement"
                            "Alter user statement"
   AlterUserStmt
```

```
AnalyzeTableStmt "Analyze table statement"
```

BeginTransactionStmt "BEGIN TRANSACTION statement"

BinlogStmt "Binlog base64 statement"

. . .

#### %type <item>

AlterTableOptionListOpt "alter table option list opt"

AlterTableSpec "Alter table specification"

AlterTableSpecList "Alter table specification list"

AnyOrAll "Any or All for subquery"

Assignment "assignment"

. . .

### %type <ident>

KeyOrIndex "{KEY | INDEX}"

ColumnKeywordOpt "Column keyword or empty"
PrimaryOpt "Optional primary keyword"

NowSym "CURRENT\_TIMESTAMP/LOCALTIME/LOCALTIMESTAMP"

NowSymFunc "CURRENT\_TIMESTAMP/LOCALTIME/LOCALTIMESTAMP/NOW"

. . .

#### 第一部分的最后是对优先级和结合性的定义:

. . .

%precedence sqlCache sqlNoCache

%precedence lowerThanIntervalKeyword

%precedence interval

%precedence lowerThanStringLitToken

%precedence stringLit

. . .

%right assignmentEq

%left pipes or pipesAsOr

%left xor

%left andand and

%left between

. . .

parser.y 文件的第二部分是 SQL 语法的产生式和每个规则对应的 aciton 。SQL语法非常复杂, parser.y 的大部分内容都是产生式的定义。

sqL 语法可以参照 MySQL 参考手册的 SQL Statements 部分,例如 SELECT 语法的定义如下:

```
SELECT
```

```
[ALL | DISTINCT | DISTINCTROW ]
  [HIGH PRIORITY]
 [STRAIGHT JOIN]
  [SQL SMALL RESULT] [SQL BIG RESULT] [SQL BUFFER RESULT]
  [SQL CACHE | SQL NO CACHE] [SQL CALC FOUND ROWS]
select expr [, select expr ...]
[FROM table references
  [PARTITION partition list]
[WHERE where condition]
[GROUP BY {col name | expr | position}
  [ASC | DESC], ... [WITH ROLLUP]]
[HAVING where condition]
[ORDER BY {col name | expr | position}
  [ASC | DESC], ...]
[LIMIT {[offset,] row count | row count OFFSET offset}]
[PROCEDURE procedure name(argument list)]
[INTO OUTFILE 'file name'
    [CHARACTER SET charset name]
    export options
  | INTO DUMPFILE 'file name'
  INTO var name [, var name]]
[FOR UPDATE | LOCK IN SHARE MODE]]
```

我们可以在 parser.y 中找到 SELECT 语句的产生式:

```
SelectStmt:
    "SELECT" SelectStmtOpts SelectStmtFieldList OrderByOptional SelectStmtLimit
    { ... }

    "SELECT" SelectStmtOpts SelectStmtFieldList FromDual WhereClauseOptional Se
    { ... }

    "SELECT" SelectStmtOpts SelectStmtFieldList "FROM"
    TableRefsClause WhereClauseOptional SelectStmtGroup HavingClause OrderByOpt SelectStmtLimit SelectLockOpt
    { ... }
```

产生式 SelectStmt 和 SELECT 语法是对应的。

我省略了大括号中的 action , 这部分代码会构建出 AST 的 ast.SelectStmt 节点:

```
type SelectStmt struct {
    dml Node
    resultSetNode
    // SelectStmtOpts wraps around select hints and switches.
    *SelectStmtOpts
    // Distinct represents whether the select has distinct option.
    Distinct bool
    // From is the from clause of the query.
    From *TableRefsClause
    // Where is the where clause in select statement.
   Where ExprNode
    // Fields is the select expression list.
    Fields *FieldList
    // GroupBy is the group by expression list.
   GroupBy *GroupByClause
    // Having is the having condition.
    Having *HavingClause
    // OrderBy is the ordering expression list.
   OrderBy *OrderByClause
    // Limit is the limit clause.
   Limit *Limit
    // LockTp is the lock type
   LockTp SelectLockType
    // TableHints represents the level Optimizer Hint
   TableHints []*TableOptimizerHint
}
```

可以看出, ast.SelectStmt 结构体内包含的内容和 SELECT 语法也是一一对应的。

其他的产生式也都是根据对应的 SQL 语法来编写的。从 parser.y 的注释看到,这个文件最初是用工具从 BNF 转化生成的,从头手写这个规则文件,工作量会非常大。

完成了语法规则文件 parser.y 的定义,就可以使用 goyacc 生成语法解析器:

```
bin/goyacc -o parser/parser.go parser/parser.y 2>&1
```

TiDB 对 lexer 和 parser.go 进行了封装,对外提供 parser.yy\_parser 进行 SQL 语句的解析:

```
// Parse parses a query string to raw ast.StmtNode.
func (parser *Parser) Parse(sql, charset, collation string) ([]ast.StmtNode, er
...
}
```

最后,我写了一个简单的例子,使用 TiDB 的 SQL Parser 进行 SQL 语法解析,构建出 AST ,然后利用 visitor 遍历 AST :

```
package main
import (
    "fmt"
    "github.com/pingcap/parser"
    "github.com/pingcap/parser/ast"
   "github.com/pingcap/tidb/types/parser driver"
type visitor struct{}
func (v *visitor) Enter(in ast.Node) (out ast.Node, skipChildren bool) {
    fmt.Printf("%T\n", in)
   return in, false
}
func (v *visitor) Leave(in ast.Node) (out ast.Node, ok bool) {
    return in, true
}
func main() {
   p := parser.New()
    sql := "SELECT /*+ TIDB_SMJ(employees) */ emp_no, first_name, last_name " +
        "FROM employees USE INDEX (last_name) " +
        "where last_name='Aamodt' and gender='F' and birth_date > '1960-01-01'"
    stmtNodes, _, err := p.Parse(sql, "", "")
    if err != nil {
        fmt.Printf("parse error:\n%v\n%s", err, sql)
        return
    }
```

```
for _, stmtNode := range stmtNodes {
    v := visitor{}
    stmtNode.Accept(&v)
}
```

我实现的 visitor 什么也没干,只是输出了节点的类型。 这段代码的运行结果如下,依次输出遍历过程中遇到的节点类型:

```
*ast.SelectStmt
*ast.TableOptimizerHint
*ast.TableRefsClause
*ast.Join
*ast.TableSource
*ast.TableName
*ast.BinaryOperationExpr
*ast.BinaryOperationExpr
*ast.BinaryOperationExpr
*ast.ColumnNameExpr
*ast.ColumnName
*ast.ValueExpr
*ast.BinaryOperationExpr
*ast.ColumnNameExpr
*ast.ColumnName
*ast.ValueExpr
*ast.BinaryOperationExpr
*ast.ColumnNameExpr
*ast.ColumnName
*ast.ValueExpr
*ast.FieldList
*ast.SelectField
*ast.ColumnNameExpr
*ast.ColumnName
*ast.SelectField
*ast.ColumnNameExpr
*ast.ColumnName
*ast.SelectField
*ast.ColumnNameExpr
*ast.ColumnName
```

了解了 TiDB SQL Parser 的实现,我们就有可能实现 TiDB 当前不支持的语法,例如添加内置函数,也为我们学习查询计划以及优化打下了基础。希望这篇文章对你能有所帮助。

作者介绍:马震,金蝶天燕架构师,曾负责中间件、大数据平台的研发,今年转向了 NewSQL 领域,关注 OLTP/AP 融合,目前在推动金蝶下一代 ERP 引入 TiDB 作为数据库

### 存储服务。

## 点击查看更多 TiDB 源码阅读系列文章

关于我们	资源中心	联系我们	PingCAP 公司
公司概况 发展历程 新闻中心 市场活动 加入我们	社区 TiDB 文档 TiDB in Action 快速上手指南 社区问答-AskTUG	商务咨询 4006790886 010-58400041 info@pingcap.com	PingCAP 是业界领先的企业 级开源分布式数据库企业,提 供包括开源分布式数据库产 品、解决方案与咨询、技术支 持与培训认证服务,致力于为 全球行业用户提供稳定高效、 安全可靠、开放兼容的新型数 据基础设施,解放企业生产 力,加速企业数字化转型升
	博客	前台总机	
隐私声明	GitHub	010–53326356	
Cookie 政策	PingCAP Education		级。
安全合规		媒体合作	
		pr@pingcap.com	

联系我们

© 2021 北京平凯星辰科技发展有限公司 京 ICP 备 16046278 号 - 2



❷ 京公网安备 11010802035112 号